

금융상품 **Agent** 기술제안

제10회 2026 미래에셋증권 AI Festival | 팀 BIGF | 나수경, 류현정, 진재언

제안서 요약

해당 Agent는 자연어 질문에 필요한 데이터와 탐색 순서를 계획하고, 정형 금융상품 데이터를 조회·비교·정렬한 뒤 근거에 기반해 답변하는 Agent RAG-QA 시스템이다. 대상은 국내채권·국내 ETF·해외 ETF·공모펀드다. 목표는 사용자가 조건에 맞는 상품을 찾고, 비교 결과가 어떤 데이터와 기준일에 근거하는지 확인할 수 있게 하는 데에 의의가 있다. 금융상품 질문은 서로 다른 종류의 판단을 요구한다. 총보수와 순자산은 정확한 필드·단위로 비교해야 하며, 투자전략은 설명문의 의미를 읽어야 한다. 기업의 자회사 관계와 ETF의 실제 편입 여부는 각각의 자료로 입증해야 한다. 따라서 해당 Agent는 이 차이를 검색 계획에 반영하여 PostgreSQL 정형 검색, 해외 ETF 전략문 키워드·벡터 검색, 기업 관계 검색을 결합하여 서비스를 제공한다.

팀의 기술적 기여는 금융 수치를 지표·기간·단위로 검증하는 규칙과, 부적격 보완값이 별칭·원문을 통해 다시 공개되지 않도록 하는 출처 처리에 있다. 원본 위치와 보완 이력을 추적하고, 미확인 값을 유지하며, 필요한 자료가 부족하면 부분 답변 또는 확인불가 사유를 제공한다.

목차

- 01 전체 아키텍처 및 특화기능
- 02 데이터·전처리·온톨로지·검색·답변·외부자료
- 03 시스템 구성도
- 04 주요 기능 흐름도와 사용자 시나리오 및 API

01 전체 아키텍처 및 특화기능

금융상품의 의미를 보존하는 검색 구조

FastAPI가 수신한 질문은 Agent의 분석·계획·검색·검증·생성 단계를 거친다. RetrievalPlan은 수행할 검색과 선행 결과 의존성을 표현하고, Evidence는 검색 결과의 상품 ID·원문·필드 값·출처·기준일을 전달한다. 서로 다른 조회기가 공통 계약을 사용하므로 검색 경로를 추가해도 답변 판단과 출력 형식을 유지할 수 있다.

주최 필수 구성요소	BIGF의 대응	구현 범위
분석·정제와 Ontology	원본 보존·결측 보완, 의미 사전·도메인 TTL	PDF 전문·청크 인계 존재, 범용 PDF/PPT→Markdown 미완성
RDB·Vector·Graph KB	PostgreSQL·pgvector·기업 관계 테이블	관계 구조를 SQL로 조회, 전용 Graph DB·OWL 추론 미사용
Intent·NL2SQL·Retrieval	규칙 분석→허용 SQL, 의존 계획과 근거 우선순위	정의된 검색 능력 안에서 계획·실행, 자유 재계획 미구현
Answer Generator	Evidence 판정→HCX→인용·수치 검증	완전·부분·불가·오류 구분, 전 범위 정확성은 평가 필요

핵심 기술

1. 금융 수치를 지표·기간·단위로 검증함.

생성 답변의 수치를 지표군·단위 차원·값으로 표현하는 GroundedMeasure를 구현했다. 지표명을 원천 컬럼에 대응시키고 단위를 환산한 뒤 인용된 근거와 비교한다. 순자산에 존재하는 숫자를 수익률로 인용하거나, 1개월 수익률을 1년 수익률로 바꾸는 오류를 검사한다. 1억원과 100,000,000원, 15bps와 0.15%처럼 같은 값의 다른 표현은 허용한다.

2. 부적격 값의 별칭과 원문 재노출을 함께 처리함.

공개 근거 생성 시 부적격 fee_rate와 같은 의미의 expense_ratio_pct를 함께 제거한다. 원문에 값이 남지 않도록 허용 필드만으로 본문을 재구성한다. 전략문도 원문·정규화문·발체문 별칭을 함께 처리한다. 결측 보완값이 다른 표현 경로를 통해 사실 근거로 재등장하는 문제를 겨냥한 구현이다.

3. 구현을 보여주는 검증 사례

두 구현의 관련 회귀 시험 22개와 하위 사례 23개가 통과했다. 같은 숫자의 다른 지표 인용, 기간 변경, 단위 환산, 비적격 별칭·전략문 제거가 시험에 포함되어 있다. 이는 규칙의 동작 검증이며 실제 금융 QA 정답률이나 경쟁팀 대비 우위를 의미하지 않는다. 규칙 기반 계획·SQL·벡터·관계 검색은 이 검증을 적용할 실행 기반으로 설명한다. 핵심 기여의 효과는 같은 질문·데이터에서 수치 검증과 출처 정제를 각각 제외한 구성과 비교하여 측정한다. 지표명 인식 범위와 공개 근거 외 경로의 출처 정합성은 후속 보완 대상이다.

02 데이터 전처리

2-1. 마스터 데이터 보존과 적재

상품군	과제 설명서 제공 건수	인계 Raw	인계 Core
국내채권	42,394	21,882	21,882
국내 ETF	1,734	1,780	1,779
해외 ETF	5,646	6,037	6,037
공모펀드	95,619	23,676	23,676
합계	145,393	53,375	53,374

원본과 검색용 구조를 분리하여 상품 ID를 중심으로 수치·별칭·전략문을 연결하였다. 데이터셋의 출처, 스냅샷, 행 위치를 보존해 답변에 사용된 값을 원본으로 역추적할 수 있게 설계했다.

2-2. 원본 위치와 변경 이력을 보존

Excel 적재기는 파일명을 NFC로 정규화해 찾고 모든 시트를 문자열로 읽는다. 식별자의 선행 0 등 표기를 유지하며 빈 문자열과 결측은 NULL로 변환한다. 원본 행을 JSONB로 보존하고 파일·행의 SHA-256, 파일명·시트명·행 번호를 기록한다. 500행 단위 적재와 데이터셋 단위 커밋·롤백을 사용한다.

스냅샷은 파일 해시로 식별하고, 행은 스냅샷·시트·행 번호 기준으로 갱신한다. 채권 원본 키는 상품번호·거래시장·정보 순번을 조합한다. 이 구조는 반복 적재 시 원본 위치와 변경 여부를 대조하는 기반이다. 다만 채권 키의 결측이 문자열로 변환될 가능성은 추가 검증 대상이다.

원본과 서비스 데이터의 계층 분리

raw는 원천 행, core는 상품군별 타입이 있는 데이터, search는 별칭·전략문·검색 함수, meta는 스냅샷·활성 버전·출처, audit는 검증 이력을 담당한다. core.accepted_source_row는 ERROR 행을 제외하고 WARNING 상태를 보존하는 조회 구조다.

수치·날짜·허용값을 구조화하면 필터와 정렬에 필요한 의미가 명확해진다. 특히 국내 순자산의 원화 단위와 해외 ETF AUM의 원 통화를 구분하고, 판매 여부의 NULL을 false로 바꾸지 않는다. 국내 ETP 원천에 ETN이 포함될 수 있으므로 실제 상품 유형도 표시 명칭과 대조해야 한다.

최신 저장소에는 보완 Excel 생성 코드와 Raw 적재 코드가 존재한다. 전체 Raw→Core 변환, 검색 자료 생성, 감사 로그→provenance 변환, 활성 버전 설정을 하나의 작업으로 재현하는 경로는 추가 정리가 필요하다. 현재 재현은 DB 인계·복원 절차와 별도 원천 자산을 함께 사용한다.

03 데이터 전처리

3-1. 금융 의미를 고려한 결측치 보완

data_quality/external_api의 6개 스크립트와 data_quality/correlation_imputation의 5개 스크립트를 제공한다.

전체적으로 보면, 빈 값을 채울 때 세 가지 방식을 썼다. 첫째는 외부 공식 API나 공식 파일에서 실제 값을 가져와 채우는 방식으로 가장 신뢰도가 높고, 둘째는 계산식으로 직접 값을 구하는 방식, 셋째는 통계적으로 가장 흔한 패턴을 추정해서 채우는 방식인데 이건 실제 값이 아니라 추정값이라는 점을 구분해서 다뤄야 한다. 그리고 확신할 수 없는 경우에는 억지로 채우지 않고 결측 상태로 남겨두는 원칙도 함께 적용했다.

공모펀드 데이터

펀드 고유 코드에 해당하는 kofia_fd_ccd 컬럼은 원래 11,431건(23.1%)이 비어 있었는데, 금융위원회의 펀드상품기본정보 API에 펀드명을 넣어 조회하고 이름이 정확히 일치하는 경우에만 값을 채택하는 방식으로 2,715건을 채워 결측을 8,716건(18.4%)까지 줄였다. 이 조회 과정에서 부수적으로 얻어지는 asoStdCd 필드값을 이용해 표준 상품번호(std_itm_no)도 175건을 함께 채웠고, 그 결과 4,599건(19.4%)이던 결측이 4,424건(18.7%)으로 줄었다. 반면 zrin_btyp_nm이라는 내부 분류 컬럼은 외부 API로는 조회할 방법이 없어서, 펀드유형(or_attr_desc)과 투자지역(ovrs_fd_desc)이라는 두 컬럼을 조합한 파생변수를 만들고, 이 조합이 같은 펀드들끼리는 값도 비슷할 것이라는 가정 아래 그 조합에서 가장 흔하게 나타나는 값을 대입하는 방식을 썼다. 다만 아무 조합에나 적용한 게 아니라 적중률이 95% 이상이고 샘플이 100건 이상인 조합에만 적용했고, 미리 정답을 알고 있는 데이터를 7대3으로 나누어 정확도를 검증한 뒤에 반영했다. 그 결과 원래 12,395건(52.4%)이던 결측 중 1,171건을 채워 11,224건(47.4%)으로 줄였는데, 이 값은 실제 조회값이 아니라 파생변수 기반의 통계적 추정값이므로 공식 조회로 채운 값과는 구분해서 취급해야 한다.

해외 ETF 데이터

통화 코드, 고가, 저가, 거래량, 기준가에 해당하는 다섯 개 컬럼이 각각 11~14건(0.2%) 정도로 소량 비어 있었는데, 이건 Yahoo Finance의 시세 조회 API로 시장 거래 데이터를 가져와 전부 채워서 결측을 완전히 없앴다. 레버리지 배수를 나타내는 cu_lev_fector는 API로 구할 수 없어서 상품명 안에 있는 "2X"나 "-3X" 같은 배수 표기를 문자 패턴으로 찾아 추출하는 방식으로 파생변수를 만들었고, 원래 5,136건(85.1%)이던 결측 중 42건을 채웠다. 정답을 알고 있는 707건을 기준으로 검증했을 때 정확도는 99.6%였다. ETN 상품 여부를 나타내는 cu_etn_yn 역시 상품명에 "ETN"이나 "Exchange Traded Notes"라는 표현이 있을 때만 Y로 채우는 파생변수를 만들되, "Vietnam"처럼 우연히 글자가 겹쳐서 잘못 걸리는 경우는 제외했다. 다만 이 규칙으로는 겨우 1건만 채울 수 있어서 5,972건(98.9%)이던 결측이 5,971건(98.9%)으로 거의 변화가 없었다. 인버스(하락 베팅) 여부를 나타내는 cu_inverse_short_yn도 마찬가지로, 앞서 만든 파생변수인

레버리지 배수가 음수인 경우에만 Y로 채우는 보수적인 규칙을 적용해 5,854건(97.0%) 중 3건만 채웠다. 이 두 컬럼은 확신이 서지 않는 나머지 값들을 일괄로 N이나 임의의 값으로 바꾸지 않고 그대로 결측으로 남겨둔 것이 특징이다. 괴리율을 나타내는 `du_diff_rt`는 종가와 기준가(NAV) 두 컬럼을 조합해 $(\text{종가} - \text{기준가}) \div \text{기준가} \times 100$ 이라는 계산식으로 새로운 파생변수를 만들어 구했는데, Yahoo에서 가져온 값을 쓴 게 아니라 원본 데이터에 실제 기준가가 남아 있는 행에서만 계산해서 6,034건(100.0%)이던 결측 중 755건을 채웠다.

국내 ETF 데이터

ETF가 추종하는 기초지수를 나타내는 `cu_base_index`는 한국거래소(KRX)의 오픈 API에서 기준일을 지정해 일별 매매정보를 조회하는 방식으로 채워서, 원래 1,724건(96.9%)이던 결측 중 1,534건을 채워 190건(10.7%)까지 줄였다. 운용 보수율을 나타내는 `cu_charge_rt`는 KRX에서 제공하는 전종목기본정보를 8월 24일 기준으로 직접 다운로드해서 1,563건(87.8%) 중 1,319건을 채웠다. 분배금 지급 주기를 나타내는 `pd_dvid_cycl`은 SEIBro(증권예탁원) API에서 과거 분배금 지급 이력을 조회한 뒤 지급 간격의 평균을 계산해서 연간, 분기, 월간 등으로 코드를 판정하는 방식을 썼고, 572건(32.1%) 중 12건을 채웠다. 나머지 560건(31.5%)은 애초에 분배금을 지급한 이력 자체가 없어서 구조적으로 채울 수 없는 결측으로 남았다. 국제 상품 코드에 해당하는 `pd_isin_cd`는 원본 상품번호가 곧 ISIN 코드와 같다는 원리를 이용해 원본 상품번호 값을 그대로 매핑한 파생변수로 채웠는데, 손상된 데이터 1건을 제외한 571건을 그대로 복사해 572건(32.1%)이던 결측을 1건(0.1%)까지 줄였다. 상장일(`pd_lstg_dt`)과 최종거래일(`pd_lste_dt`)은 각각 6건(0.3%)씩 비어 있었는데, 그중 3건을 KRX 전종목기본정보를 수동으로 다운로드해서 채웠다. 상장일은 기존에 있던 값과 100% 교차검증을 거쳤고, 최종거래일은 ETN 전용 파일에만 존재하는 필드에서 값을 가져왔다.

04 온톨로지

금융상품 데이터 탐색적 분석(EDA) 및 설계 시사점

1. 분석 목적 및 데이터 구성

해당 Agent의 금융상품 검색·질의응답 설계를 위해 2026년 8월 24일 배포된 국내채권, 공모펀드, 국내 ETF, 해외 ETF 데이터를 분석하였다. 분석은 상품군별 데이터 규모, 스키마 정합성, 중복·결측, 주요 지표의 분포 및 기준일을 중심으로 수행하였다. 이를 통해 질문 유형별로 활용 가능한 정보와 추가 검증이 필요한 항목을 구분하였다.

주최 필수 구성요소	BIGF의 대응
common.ttl	공통 상품 계층, 기업·증권 관계, 위험등급, 투자자산군, 테마·지역, 근거 문서, 관계 이력 및 상장 정보

bond_kr.ttl	국내채권의 신용등급, 표면금리, 매수수익률, 만기 및 잔존일수
etf_kr.ttl	국내 ETF의 원화 순자산 및 표시 통화 검증
etf_gl.ttl	해외 ETF의 원통화 순자산, 증가, 거래량 및 필수 식별 정보
fund_pub.ttl	비상장 공모펀드 클래스 상품의 순자산, 벤치마크, 환헤지 정책 및 기간별 수익률

모든 데이터셋에서 제공 스키마와 실제 컬럼 구성이 일치하였다. 다만 전체 행이 동일한 중복이 없다는 사실이 상품 식별자의 유일성을 의미하지는 않는다. 국내채권의 상품번호는 20,497개로 전체 행 수보다 적으며, 시장 및 판매 LOT 구분을 고려해야 한다. 따라서 총 53,375행은 고유 금융상품 수가 아닌 분석 대상 레코드 수로 정의하였다.

2. 상품군별 결측 패턴과 정보 활용 범위

결측은 상품군과 정보 유형에 따라 서로 다른 양상을 보였다. 이에 전체 결측률뿐 아니라 실제 질문에 필요한 필드의 확보 여부를 기준으로 데이터 활용 범위를 판단하였다.

| 상품군 | 주요 분석 결과 | 시스템 설계에 대한 시사점 |

| 국내채권 | 민평수익률·표면이자율은 결측이 없지만, 매수수익률·개인 세후 운용수익률·매매단가 등은 각각 97.10% 결측 | 평가 지표와 판매 조건을 구분하고, 민평수익률을 실제 매수금리로 대체하지 않음 |

| 공모펀드 | 전체 결측률이 가장 높으며, 1개월 수익률은 68.80%, 1년 수익률은 70.34% 결측. 1주일 수익률은 전부 결측 | 기간별 수익률 질문의 답변 가능 여부를 개별 판정하고, 데이터가 있는 상품만 비교 |

| 국내 ETF | 1년 수익률은 20.45%, 총보수요율은 87.81% 결측.

듀레이션·수정듀레이션·평균잔존만기·원천 성과배분/분배금은 전부 결측 | 수익률·비용·채권형 특성 등 질문별로 사용 가능한 필드를 구분하고, 부족한 정보의 보완 우선순위 설정 |

| 해외 ETF | 연간보수율은 결측이 없고 운용전략 결측률은 0.18%인 반면, 추정 주당 NAV는 87.44%, 추정 NAV 괴리율은 99.95% 결측 | 전략 설명과 보수 조건 검색에 우선 활용하고, NAV·괴리율 비교는 근거 확보 여부를 확인 |

이러한 결과는 모든 상품군에 동일한 필드와 결측 처리 규칙을 적용하기 어렵다는 점을 보여준다. 특히 결측을 0이나 '해당 없음'으로 일괄 대체하면 미확인 정보를 실제 수치 또는 부정 조건으로 오인할 수 있다. 따라서 원본 결측 상태를 보존하고, 미제공·비적용·연결 누락 등의 원인은 추가 검증을 통해 구분하도록 설계한다.

3. 수치 분포와 극단값 검증

주요 수치 지표에서는 중앙값과 최댓값 사이의 차이가 크게 나타났다. 국내채권 민평수익률은 중앙값 4.092, 최댓값 728.524였으며, 국내 ETF 괴리율은 중앙값 0.07, 최댓값 17,545.23으로 확인되었다. 공모펀드에서는 일부 자산구성비율이 음수이거나 100을 초과하였다.

이 값들은 우선 검증 대상으로 분류한다. 분포만으로 오류를 확정하지 않고 상품 구조, 산출 방식, 단위 및 원천 자료를 확인해야 한다. 특히 수익률이나 괴리율을 기준으로 상품을 정렬할 때 극단값이 상위 결과를 지배할 수 있으므로, 원본값과 검증 상태를 함께 관리하고 확인되지 않은 값을 추천 근거로 직접 사용하지 않도록 한다.

또한 국내 ETF의 연간 추정 분배금과 해외 ETF의 추정 NAV처럼 스키마에 추정 성격이 명시된 항목은 확정 실적과 구분한다. 답변에서도 원천값·추정값의 성격을 유지하여 예상 분배금을 실제 지급 실적으로 표현하지 않도록 한다.

4. 기준일 차이와 상품 식별 문제

배포일이 같더라도 개별 지표의 기준일은 일치하지 않았다. 국내채권의 판매·민평 공통 기준일은 2026년 8월 21일이었으나, 공모펀드 기준가·수익률 기준일은 2018년 10월부터 2026년 8월까지 분포하였다. 해외 ETF의 종가 원천 기준일 역시 2025년 7월부터 2026년 8월까지 차이가 있었다.

따라서 배포일을 모든 값의 최신성 기준으로 사용하지 않고, 답변에 활용하는 필드의 기준일을 개별 확인해야 한다. 상품 간 비교에서도 기간·기준일·통화를 함께 검증하도록 한다.

상품명만으로 대상을 식별하는 데에도 한계가 있었다. 해외 ETF는 6,037행에 비해 고유 상품명 6,009개였으며, 공모펀드 역시 23,676행에 비해 고유 종목명이 23,624개였다. 이에 상품명은 검색 진입점으로 활용하되, 최종 조회와 문서 연결은 상품번호·RIC 등 검증된 식별자를 중심으로 수행한다. 펀드는 클래스 구분을, 채권은 시장·판매 LOT 구분을 함께 고려한다.

5. EDA를 반영한 Agent 검색·응답 설계

분석 결과를 바탕으로 BIGF는 다음과 같은 설계 원칙을 적용한다.

- 공통 의미와 상품별 원본 필드 연결: 상품명·통화·위험등급 등은 공통 검색 항목으로 연결하되, 민평수익률·매수수익률·기간 수익률처럼 의미가 다른 지표는 구분한다.
- 질문 유형별 검색 경로 구성: 수익률·보수·순자산 조건은 구조화 조회로 처리하고, 투자전략 등 서술형 정보는 키워드·벡터 검색에 활용한다. 해외 ETF 운용전략은 결측률이 낮고 고유값이 5,943개로 다양하여 설명 검색의 우선 활용 대상으로 판단하였다.
- 필수 근거 기반 응답 판정: 질문에 필요한 필드의 존재 여부, 기준일, 단위, 추정 여부를 확인한 뒤 완전 답변·부분 답변·답변 불가를 구분한다.
- 데이터 보완 우선순위 설정: 공모펀드 수익률, 국내 ETF 보수, 채권 판매 조건 등 서비스 질문에 직접 영향을 주는 결측 항목부터 공식 자료를 통한 보완을 검토한다.

이번 EDA는 데이터 품질과 검색 설계의 근거를 확보하기 위한 분석이다. 결측의 발생 원인, 극단값의 정상 여부, 검색 정확도 향상 효과까지 입증한 것은 아니다. 후속 단계에서는 상품 식별 정확도, 조건 충족 여부, 근거 적합성 및 결측 질문에 대한 응답 판정 정확도를 별도로 평가한다.

05 검색

5-1. 질의 해석과 검색 방법론

해당 Agent의 NL2SQL은 자연어→구조화 계획→허용된 SQL의 제한형 변환이다. 분석기는 규칙과 사전으로 상품군, 식별 표현, 수치·통화·등급 조건, 정렬, 테마와 기간을 추출한다. 계획기는 필요한 조회와 보조 조회를 나누고, 선행 결과에 의존하는 단계를 명시한다. 이 방식은 지원 범위와 실패 지점을 코드에서 추적하기 쉽다.

검색	구현 방법	금융 질문에서의 역할
상품 식별	정확 별칭 우선, 부분일치·trigram 후보	다른 상품의 값·문서 연결 방지
정형 검색	허용 필드·연산자와 SQL 파라미터 바인딩	수치 조건, 범주 조건, 정렬·상위 N개
전략 키워드	PostgreSQL FTS·부분일치·pg_trgm	명시적인 용어가 있는 해외 ETF 전략 탐색
전략 벡터	pgvector 코사인 유사도	표현이 달라도 의미가 가까운 전략 후보 탐색
기업 관계	관계 테이블과 1단계 SQL 조회	방향·출처·기준일이 있는 기업 연결 확인
외부자료	capability별 전용 조회기	편입종목·공사·투자설명서 근거 확보

5-2. 조건을 만족하는 후보 안에서 의미를 비교

정형 조회는 전체 조건 후보를 정렬한 뒤 결과 수를 제한하며, 지원되는 순자산·1년 수익률·보수율 정렬에서 결측을 뒤로 보낸다. 여러 선행 검색 결과를 연결할 때는 상품 ID 교집합을 적용한다. 지원하지 않는 필드·정렬은 실행 전 검사로 구분하되, 분석기가 추출하지 못한 자연어 조건까지 모두 검출하는 것은 아니다.

해외 ETF 벡터 검색은 ACTIVE 스냅샷, 정형 조건과 선행 후보를 적용한 뒤 유사도를 계산한다. 따라서 질문의 지역·상품 조건과 의미 검색을 같은 후보 범위에서 연결할 수 있다. 기본 모델은 Qwen/Qwen3-Embedding-0.6B이며 1,024차원·정규화 벡터·최대 길이 512를 사용한다. 적재와 질문 임베딩이 설정을 공유하고 모델명이 다른 벡터는 재생성 대상으로 관리한다.

5-3. 여러 검색의 근거를 보존하는 결합

EvidenceFusion은 중복을 제거하고 정형·편입·관계·문서·이벤트·키워드·벡터의 우선순위와 점수로 근거를 정렬한다. 필수 검색 경로의 근거를 우선 확보한 뒤 최대 50개를 선택한다. 이는 수치 비교 근거와 설명문 근거가 함께 남도록 하는 장치이며, 값의 출처 충돌 해결기와는 별개다.

현재 운영 키워드는 FTS 기반이며 BM25·RRF·학습형 재순위화를 적용한 것으로 표현하지 않는다. 관계검색은 전용 Graph DB·SPARQL 실행 없이 PostgreSQL에서 1-hop으로 구현한다. HNSW·IVFFlat ANN 인덱스와 전 상품군 문서 벡터 검색은 후속 확장 대상이다.

06 답변

6-1. 답변 생성과 근거 표시

검색 결과는 상품·레코드 ID, 원문, 구조화 값, source_ref, 기준일, 점수와 provenance를 가진 Evidence로 전달된다. 검증기는 질문의 상품군·조건·선행 후보와 근거가 맞는지 검사한다. 이후 답변 정책이 필수 자료의 확보 여부와 검색 범위를 판단한다.

상태	판정 의미	응답 방식
complete	필요한 근거와 검색 범위 조건 충족	확인된 정보로 답변 생성
partial	일부 자료나 검색 범위 부족	가능한 설명과 부족한 근거를 함께 안내
unanswerable	핵심 근거 부족·식별 모호성 등	현재 자료로 확인할 수 없음을 안내
error	필수 조회 실패 등 실행 오류	자료 부재와 구분한 오류 안내

정상 검색 0건은 자료 미적재와 구분한다. 데이터가 준비되고 적용한 조건에 일치하는 결과가 없을 때에는 해당 검색 범위의 무결과를 안내한다. 반면 필요한 자료가 없거나 조회 범위가 제한된 경우에는 존재하지 않는다고 단정하지 않는다. 이 판정의 신뢰도는 각 조회기가 보고하는 커버리지의 정확성에 달려 있다.

6-2. CLOVA Studio의 역할

생성 가능한 경우 HCX 클라이언트가 검색 근거를 한국어 문장으로 정리한다. Chat Completions v3와 환경변수 모델 설정을 사용하며 예시 모델은 HCX-005다. 프롬프트는 근거만 사용하고 상품명·티커를 유지하며 사실 문장에 [evidence_id]를 붙이도록 요구한다. 검색 문서 속 지시문은 참고 데이터로 취급하도록 명시한다.

생성 후 검사는 인용 ID, 상품명·티커·ISIN, 날짜, 필드 의미·단위·수치·출처를 대조한다. 수치 주변 40자 이내의 지표명 후보를 거리와 방향으로 선택하고, 원천 컬럼을 지표군에 매핑한다. 비교 조건은 지표군·단위 차원 일치와 수치의 근사 일치다. 1개월·1년 등 명시적 수익률 기간도 구분한다. 원·만원·억원·조원은 원으로, bp는 퍼센트 단위로 환산한다. 존재하는 ID를 인용했다는 이유만으로 문장 전체가 검증되었다고 판단하지 않도록 세부 검사를 둔다.

6-3. 출처 적격성과 대체 응답

DB에는 원본·공식 보완·수동 검증·추정값을 구분하는 출처 구조가 있다. 공식 보완에는 출처와 날짜, 수동 검증에는 검수 정보가 필요하며 **estimated** 값은 부적격으로 처리하도록 정의한다. 공개 근거 직렬화는 비적격 값과 해당 표기를 정제한다. 모든 후보 선별·LLM 비정형 컨텍스트에 동일 정책이 일관되게 적용되는지는 추가 점검 대상이다.

응답 불가·오류·정상 0건은 LLM을 호출하지 않는다. HCX 미설정·시간 초과·빈 응답·생성 검증 실패 시 결정론적 요약으로 전환한다. 현재 대체 요약은 최대 10개 근거의 상품명·일부 내용 중심이며 완전한 비교표나 문장별 인용의 품질은 보완해야 한다.

retrieved_context는 근거 ID·값·출처·기준일을, **think_trace**는 실행 경로와 판정 요약을 전달한다. 이 구조는 답변의 재검토를 돕는다. 규칙 기반 검사가 모든 자연어 오류를 막는다는 보장은 하지 않으며, 근거 없는 전망·단정적 추천 요청은 별도 평가군으로 검증한다.

07 외부데이터

7-1. 외부데이터와 문서의 활용

질의 시점의 외부자료 조회는 PostgreSQL에 미리 적재된 자료를 대상으로 한다. 편입종목은 KRX·SEC, 공시는 OpenDART, 위험요인은 투자설명서 조회기로 연결한다. 수집·보완용 외부 API 스크립트는 오프라인 데이터 준비 작업이며 질문마다 웹을 탐색하는 기능과 구분하였다.

자료	연결 방식	현재 범위
KRX·SEC 편입	원천 보유 테이블과 상품 매핑, ext 검색 함수	KRX 2026-08-24·SEC 적재 보고일 기반 조회
OpenDART 공시	상품→운용사→공시 연결	운용사 공시이며 상품 테마 이력과 동일하지 않음
투자설명서	상품 키→접수번호→구역·청크	인계 파일 존재, 운영 함수·전체 적재 별도 확인
기업 관계	기업 식별자와 관계 행	출처·방향·기준일·ACTIVE 스냅샷 기반

7-2. 투자설명서를 상품 단위 근거로 만드는 방법

OpenDART 인계 자료는 **source_product_key**를 국내 ETF 원본 **pd_itm_no_ma**에 연결하고, **rcept_no**로 문서·구역·청크·사실·공시를 연결한다. 전문, 정정 공시, 표지·요약을 구분하고 **usable_for_rag=true**인 전문을 검색 근거 후보로 지정한다. 자동 연결을 확정하지 않은 항목은 **link_review.csv**에 분리한다.

2026-08-24 기준 manifest에는 대상 1,213건, 사용 가능 전문 1,211건, 전문 미확보 2건, 권장 검색 청크 71,236건, 구조화 사실 2,862건이 기록되어 있다. 문서·권장 청크·상품 연결표·사실·미확보 목록 5개 파일의 행 수와 SHA-256이 manifest와 일치함을 확인했다. 이는 로컬 전달 자료 검증이며 운영 DB 적재 건수가 아니다. **is_complete=false** 상태도 유지한다.

정정 공시는 변경 발생과 변경 내용을 확인하는 자료로 사용하고 전문을 대신하지 않는다. 이 구분은 최신 접수번호만 선택했을 때 정정 비교표를 전체 투자설명서로 오인할 위험을 줄인다. 현재 저장소의 설명서 조회기는 존재하지만 **ext.search_prospectus_chunks** 함수 정의와 전체 적재 경로는 별도 확보가 필요하다.


7-3. 주최 데이터 우선과 기준일 관리

동일 상품·필드·기준의 값이 충돌하면 주최 제공 데이터를 우선한다. 외부자료는 결측 보완이나 별도 사실 설명에 활용하며, 최신 외부값이라는 이유로 평가 기준값을 대체하지 않는다. 현재 보완 스크립트의 기존 값 보존과 provenance가 이 원칙의 기반이고, 전체 충돌 해결과 적격성 연결은 보완 단계다.

주최 스냅샷일, DB ACTIVE 스냅샷일, 편입 보고일·공시일·관계 기준일을 구분한다. API에는 계획기의 snapshot_date가 아직 주입되지 않아 “최근 N개월”의 기준일을 통일해야 한다. Yahoo 코드는 현재 응답에 고정 수집일 문자열을 기록하므로 과거 기준일 조회를 보장하지 않는다. 외부값의 실제 관측일·통화·필드 의미를 확인한 뒤 사용한다.

08 시스템 구성도

8-1. 적재부터 답변까지의 전체 구성



실선: 구현된 호출·조회 구조 점선: 전체 재적재 연결을 보완할 자료 준비 구간
PR의 5개 TTL은 의미 명세이며 현재 API의 직접 로딩·OWL 추론에는 연결되지 않음

8-2. 오프라인 데이터 준비

주최 마스터와 공식 보완 자료에서 검색용 데이터를 준비한다. 보완 스크립트는 원본 파일과 분리된 누적 결과·감사 로그를 만들고, Raw 적재기는 파일·행 위치를 보존한다. Core·별칭·전략문·관계·출처가 준비된 DB에 임베딩과 외부자료 검색 함수를 연결한다. 전체 변환·적재 재현에는 인계 데이터와 누락된 연결 절차가 함께 필요하다.

온톨로지 5개는 공통 의미와 도메인 제약의 제출 산출물이다. 현재 API는 Python 의미 사전을 참조하므로 TTL과 실행 사전의 동기화는 별도 통합 단계로 둔다. 투자설명서 전달 자료도 운영 검색 적재 여부와 구분한다.

8-3. 온라인 질문 처리

API 어댑터는 BAgentPipeline을 호출하고 실제 조회기를 capability별로 등록한다. 파이프라인은 규칙 분석과 계획 검증, 의존성을 따르는 검색, 근거 검증·결합, 답변 가능성 판정, HCX 생성·검증을 수행한다. 실패·부족 상태는 최종 응답으로 전달한다.


8-4. 배포와 데이터 변경 관리

Docker Compose는 Python 3.11 API와 `pgvector/pgvector:pg18` DB를 정의한다. API는 CPU용 `torch-sentence-transformers`를 사용하고 8000번 포트를 제공한다. DB는 내부 네트워크와 영속 볼륨을 사용한다. `init/01_schema.sql`과 버전 마이그레이션은 스키마 변경을 관리하며, 전체 ext 원천 자료를 자동 생성하는 번들은 아니다.

기술 선택의 목적은 정형·벡터·관계 검색의 운영 기반을 PostgreSQL로 모아 연결 복잡도를 관리하는 것이다. 여러 독립 DB의 분산 실행이나 전용 Graph DB 도입을 완료했다는 의미는 아니다.

09 주요 기능 흐름도

9-1. 데이터와 의미 모델의 준비 흐름



자료의 운영 적재와 조회 범위는 별도 확인하며, 부족한 근거는 답변 상태에 반영한다.

1. 원본의 제공 버전과 파일 해시를 확인하고 상품군별 식별 키를 정한다.
2. 필요한 결측에 보완 규칙을 적용하고 출처·처리 이력을 남긴다. 검증되지 않은 추정값은 사실 근거와 구분한다.
3. Raw에 원본 위치를 보존하고 Core·별칭·전략문·기업 관계·문서 매핑을 준비한다. 전체 변환 자동화는 보완 범위다.
4. 온톨로지의 클래스·속성·단위를 실행 필드에 대조하고, 관계 행과 원문을 출처·기준일로 연결한다. TTL의 적재 검증 자동 연동은 후속 통합이다.
5. ACTIVE 버전, 임베딩 모델, 문서 사용 가능 상태와 검색 함수를 확인해 평가용 데이터 범위를 고정한다.

9-2. 기업 관계에서 상품 위험요인까지



자료의 운영 적재와 조회 범위는 별도 확인하며, 부족한 근거는 답변 상태에 반영한다.

“A 기업의 자회사를 편입한 국내 ETF 중 순자산이 큰 상품의 위험요인”은 기업 관계→편입 조회→정형 조건·정렬→문서 검색의 의존 계획으로 다룬다. 자회사 방향을 확인한 뒤 반환된 기업을 편입 자료에서 찾고, 상품 ID로 순자산과 위험 문서를 연결한다. 관계 사실, 편입 사실, 위험 설명은 각각의 근거를 유지한다.

현재 관계검색은 1-hop이다. 외부 편입 조회는 정규화 대상 중 1개를 검색하며 여러 대상일 때 불완전성을 표시한다. 따라서 여러 자회사 전체의 편입 상품을 빠짐없이 찾는 완료 시연으로 제시하지 않는다. 관계 대상 ID·이름과 실제 편입 매핑의 종단 검증도 필요하다.

9-3. 검색 성공과 답변 가능성의 분리

선행 검색이 실패하면 의존 단계를 차단하거나 건너뛰고 사유를 전달한다. 정상 0건은 선행 검색의 완전성과 함께 판단한다. 상품 후보를 찾았어도 위험요인 문서를 확보하지 못했다면 확인된 후보와 문서 부족을 분리해 부분 답변한다. 핵심 근거가 없으면 확인불가로 처리하였다.

이 흐름의 효과는 결과 하나를 얻기 위해 조건을 생략하지 않고, 검색이 도달한 범위와 남은 공백을 응답에 드러낼 수 있다는 데 있다.

10 사용자 시나리오

10-1. 사용자 시나리오

아래는 구현된 검색 경로를 설명하는 시나리오다. 운영 DB에서 얻은 정답·응답속도 시연이 아니며, 구체적인 상품이나 수익률을 가정해 성과로 제시하지 않는다.

사용자 질문	처리 경로	제공 가치와 현재 범위
국내 ETF 중 1년 수익률이 높은 상품 3개	정형 조건→정렬→근거 검증	지원 지표의 비교와 출처 확인, 운영 데이터 필요
미국에 투자하는 해외 ETF의 AI 전략	지역 선필터→전략 의미 검색	투자지역과 전략 의미를 함께 탐색
특정 ETF의 위험요인	상품 식별→설명서 구역 조회	같은 상품의 전문 근거 연결, ext 적재 필요
A 기업 자회사를 편입한 국내 ETF	관계→편입→정형 후보	기업 관계와 편입 사실 분리, 1개 대상 조회 제한
최근 6개월 우주항공 관련 이력	기간·이벤트→후보 확인	기준일 주입과 상품별 테마 이력 자료 보완 필요
출처 없는 미래 수익률 전망	자료·답변 가능 범위 판정	근거 없는 전망을 생성하지 않는 평가 대상

10-2. 비교 결과가 설명 가능하려면

“총보수가 낮고 운용 규모가 큰 상품”을 비교하려면 총보수 필드와 정렬 방향, AUM 단위·통화, 상품 유형과 상장시장을 정확히 해석해야 한다. 해당 Agent는 허용 필드와 단위 사전, SQL 정렬, 생성 후 수치 검증으로 이를 다룬다. 다만 과제 설명서의 복합 문장은 현재 파서에서 미국 상장시장과 미국 투자지역을 혼동하고 보수 방향·주식형·복수 기준을 충분히 표현하지 못한다. 해당 예시는 개선·회귀 시험으로 관리한다.

10-3. 모호한 질문과 확인불가 질문

상품 식별이 모호하거나 필요한 자료가 부족하면 “현재 적재된 데이터만으로는 이 질문을 검증해 답할 수 없습니다”라는 안내에 사유를 더한다. 정확한 티커·ISIN 또는 추가 자료가 필요한 상황을 구분한다. 현재 API에 다회차 역질문 기능이 완성된 것으로 기술하지 않는다.

10-4. 판매 가능 상태의 표현

ETF·공모펀드 판매 상태는 가능·불가·미확인을 구분하고 마스터 기준 매수 후보로 설명한다. 계좌·시각별 주문 가능 여부와 동일하지 않다. 채권에도 전용 조건 조회 경로가 있으나 신용등급 SQL 컬럼 참조 불일치를 확인했으므로, 수정·검증 전 AA- 이상 필터의 정상 동작을 완료 성과로 제시하지 않는다.

11. API

11-1. 평가용 API 명세

저장소 README의 endpoint는 <http://49.50.142.6:8000/answer>다. 코드 기준 요청·응답 명세는 아래와 같다. 현재 주소의 가용성과 실제 DB·HCX 연결은 운영 검증 단계에서 확인한다.

요청: GET /answer에 `question_id`와 URL 인코딩한 `question`을 전달한다. 인증 헤더·POST 본문을 요구하지 않는다. 코드상 두 파라미터에 기본값이 있어 누락 자체를 거부하지 않으며, 평가 요청에서는 두 값을 모두 제공한다. 미정의 추가 파라미터는 일반 요청 처리에 영향을 주지 않는다.

응답 필드	타입	내용
<code>question_id</code>	string	요청 문항 ID
<code>question</code>	string	요청 질문 원문
<code>retrieved_context</code>	string	근거 ID·값·본문·기준일·출처의 직렬화
<code>think_trace</code>	string	질문 유형·조회 경로·검증 상태의 처리 요약
<code>answer</code>	string	최종 답변 또는 확인불가·오류 안내

```
curl -G 'http://49.50.142.6:8000/answer' \  
  --data-urlencode 'question_id=Q-001' \  
  --data-urlencode 'question=국내 ETF 중 1년 수익률이 높은 상품 3개'
```

호출에서 응답까지

API는 어댑터에 질문을 전달하고 BAgentPipeline의 계획·실행·검증·생성 결과를 받는다. 어댑터는 공개 근거의 비적격 값을 정제하고 다섯 문자열 필드로 반환한다. 확인불가와 내부 오류도 같은 응답 구조를 유지하며, 처리 예외의 자격증명 포함 가능 상세 문자열은 공개하지 않는다. `think_trace`는 실행 요약으로 내부 사고과정 원문과 구분한다.

시간 예산과 운영 상태

일반 DB 경로는 연결 풀 최대 5개, 연결 대기·SQL 제한을 사용하며 외부 조회는 별도 연결 제한을 둔다. HCX는 기본 요청 시간 제한과 남은 생성 예산을 고려한다. 파이프라인은 분석·검색·검증·LLM·전체 소요시간을 기록할 수 있다.

이 설정만으로 문항당 60초 이내를 보장하지 않는다. 최초 임베딩 모델 로딩, 동시 요청 대기, 외부 함수 실행을 포함한 종단 p50·p95·최대 시간을 측정해야 한다. /health의 DB 확인과 모델 설정 표시는 모델 실제 호출 성공의 증거가 아니며 readiness도 주로 DB 상태를 확인한다.

Docker의 restart 정책과 healthcheck 정의는 존재한다. unhealthy 상태만으로 자동 재시작이 보장된다고 해석하지 않는다. 운영 단계에서는 API 가용성, DB·검색 자료, HCX 호출, 시간 초과와 대체 응답을 함께 확인한다.

12. 기대효과 및 확장성

현업에서 기대하는 효과

해당 Agent는 금융 상품 탐색과 설명 자료 확인 업무를 지원한다. 조건에 맞는 후보를 찾는 단계와 수치·투자전략·위험요인의 근거를 확인하는 단계를 연결하여, 담당자가 원천 자료를 대조할 수 있는 출발점을 제공한다. 아래 효과는 설계상 기대이며 정량 개선율은 아직 측정하지 않았다.

적용 업무	기대효과	검증할 지표
상품 조건 비교	단위·결측·정렬 기준의 일관성	조건 위반률, 순위 정확도, 수치 정확도
전략과 위험 설명	상품 ID로 연결된 원문 확인	문서 연결 정확도, 근거 문장 적합성
기업 관련 상품 조사	관계와 편입 근거의 구분	관계 방향 정확도, 편입 검색 커버리지
품질 검토와 재현	출처·기준일·보완 이력 추적	출처 누락률, 비적격 값 노출률
답변불가 대응	불충분한 자료의 범위 명시	확인불가 정확도·재현율, 불필요한 거절을

같은 근거 계약으로 상품군을 확장

신규 상품군은 클래스·논리 필드·단위·허용 연산자를 정의하고 원천 키와 상품 ID 매핑을 추가하는 방식으로 확장한다. 조회기가 기존 EvidenceRetrievalBatch 계약을 반환하면 검증·판정·생성 계층을 재사용할 수 있다. 상품군별 예외를 명시적으로 다루는 것이 확장의 전제다.

단계별 고도화

우선 단계는 의미와 출처의 통합이다.

5개 TTL과 실행 사전의 충돌을 해소하고, 보완 감사 로그를 provenance에 연결한다. 공식 조회·계산·추정값을 구분하고 상품·기준일별 검증을 수행한다. Raw→Core·검색·문서의 재적재 절차도 함께 고정한다.

다음 단계는 질의 범위의 확장이다.

복합 정렬과 상장시장·투자지역 구분, API 기준일 주입, 여러 기업을 대상으로 한 편입 검색, 전 상품군 설명서 검색을 보강한다. 역질문이 필요한 조건을 구조화해 다회차 확인 흐름으로 확장할 수 있다.

성능 개선은 측정 결과에 따라 적용한다.

임베딩 사전 로딩과 배치 생성, 질의 캐시, ANN 인덱스, 문서 재순위화를 후보로 두고 정확도·검색 시간·메모리 사용량을 함께 비교한다. 다단계 관계 탐색이나 전용 Graph DB는 실제 관계 깊이·데이터량·운영 비용을 확인한 뒤 도입 여부를 결정한다.

운영 비용 관리

현재 배포 정의는 PostgreSQL과 CPU 임베딩 실행을 기반으로 한다. 월 비용은 서버·스토리지·백업·전송료와 HCX 사용량으로 나누어 산정하고, 질문당 비용은 실제 입력·출력 토큰과 호출률로 계산한다. 확정 견적·트래픽·실측 토큰이 없어 비용 절감액이나 ROI를 수치로 제시하지 않는다. 답변불가에서 LLM을 생략하는 경로와 모델 재사용은 비용·지연을 줄일 수 있는 구현 기반이다.

13. 기타

A 온톨로지와 저장 계층 대응

개념	제안 TTL의 의미	현재 실행 연결과 후속 작업
금융상품	Product·FinancialProduct와 상품군 클래스	Python 상품군·필드 사전 사용, TTL 동기화 필요
증권과 발행사	Security→isIssuedBy→Issuer	실제 증권·기업 매핑과 RDF 변환 필요
보유와 노출	holds→Security, hasExposureTo→Organization	기존 holds→Organization 의미와 충돌 해소
자회사·계열	직접 자회사·대칭 계열 관계	SQL 관계 테이블의 1-hop 조회
테마·지역	SKOS 9개 테마·6개 지역	어휘·지역 ID와 실행 사전의 회귀 검증 필요
수치·통화	decimal 지표, 원화·원 통화의 구분	FIELD_REGISTRY·SQL 컬럼·단위 대조
판매 상태	boolean 속성과 값 누락	마스터 true·false·NULL 및 검증 출처 사용
문서·공시	상품에 연결할 별도 자료	상품 키·접수번호·구역·청크 매핑

B 온톨로지 검증 결과와 수정 방향

5개 TTL은 파싱과 meta-SHACL을 통과했고 합집합은 452개 트리플이다. RDFLib 7.6.0·pySHACL

0.40.1에서 명시적으로 함께 로드하고 추론·원격 imports를 끈 조건으로 검증했다. 샘플의 위험등급 범위 초과·타입 오류와 필수값 누락을 거부하는 규칙을 확인했다.

재리뷰에서는 정상 보유 예시와 자회사→발행 증권→ETF의 SPARQL 예시를 확인했다. 이는 가상 데이터의 정의 검증이며 운영 API가 RDF 추론을 실행한다는 의미가 아니다. 다음 보완은 PR 코멘트에 남겼다.

- 채권 등급 AAAA와 문자열 수치가 통과하므로 BondShape에 실제 원천 등급 체계와 수치 datatype 제약을 추가한다.
- 같은 상품에 위험등급 2·6 또는 복수 AUM이 동시에 통과한다. 스냅샷당 단일 속성은 maxCount를 적용하고, 시계열은 값·기준일·출처를 가진 Observation으로 분리한다.
- 루트 TTL·실행 사전·새 TTL의 holds 의미를 정합화하고 재현 가능한 검사기·정상 및 오류 fixture를 저장소에 포함한다.

C 데이터 계층의 역할

raw의 원본 위치, core의 상품 키·타입, search의 별칭·문서·벡터, meta의 버전·출처, audit의 검증 이력을 연결한다. 이 계층 설계가 자동화 완료를 의미하지는 않는다. 보완 Excel의 추정값이 원본으로 분류되지 않도록 감사 로그의 키·필드·보완 유형을 함께 전달하는 적재 계약이 필요하다.